Maskinlæringsprosjekt - rapport

DAT158 Maskinlæring og avanserte algoritmar

Torodd F. Ottestad | 31. oktober 2026

Innhald

1 Problemskildring . . . 2
1.1 Business . . . 2
1.2 Metrikkar . . . 2
1.3 Ressursar . . . 2
1.4 Avgrensingar . . . 2
2 Data . . . 3
2.1 Kjelder og lisensar . . . 3
2.2 Label . . . 3
2.3 Rydding av turdata . . . 3
2.4 Rydding av vêrdata . . . 3
2.5 Utforsking . . . 4
2.6 Features . . . 5
2.7 Tidsdeling . . . 5
2.8 Personvern . . . 6
3 Modellering . . . 6
3.1 Baseline og treningsperiode . . . 6
3.2 Modellar . . . 6
3.3 Test . . . 7
3.4 Feilanalyse og viktigheit . . . 7
4 Deployment . . . 9
5 Refleksjonar . . . 10
6 Referansar . . . 10

1 Problemskildring

Målet med dette prosjektet er å laga ein maskinlæringsmodell som kan gje ein prognose på korleis bysykkelbehovet eit gitt tidspunkt med gitte vêrtilhøve vil vera. Ein kan sjå for seg at ein driftsleiar skal planlegga morgondagen, kvar vil det gå tomt for syklar, korleis vil vêrmeldinga påverka kva stasjon som blir tom og kor det hopar seg opp? Det overordna behovet er å vita kvar syklane vert borte.

Dette prosjektet tek første steg og predikerer totalt tal på turar per time. Sidan det er mange faktorar som påverkar kvarandre her, og verkar saman, blir det naturleg å nytta maskinlæring. Dagens system byggjer på varsling når stativa nærmar seg tomme (*Om Bergen Bysykkel - Bergen Bysykkel*, 2026). Utan maskinlæring kan ein bruke snittet for same tidspunkt og vekedag tidlegare år. Ein kan sjå for seg at maskinlæring kan erstatta noko av tida brukt til planlegging, og kanskje effektivisere drifta.

1.1 Business

Eit verktøy som dette kan ha ulike gevinstar. Ein kan sjå føre seg at det er enklare å planlegga for tal sjåførar og mekanikarar som skal på skift, kva dagar ein kan ta syklar inn til vedlikehald samt informasjon om effektiviteten og distribusjonen av sykkelflåten. Overbemanning fører til løn utan arbeid, og underbemanning resulterer i tomme stasjonar og sure kundar. Det vil difor vera bra for operatøren å optimalisera planlegginga her. Den manuelle løysinga der ein nyttar historiske data er ein baseline som maskinlæringsmodellen må slå for å vera nyttig. Minimumskravet for at prosjektet skal vera ein suksess er at modellen slår baseline på testsettet.

1.2 Metrikkar

Eg vil i utgangspunktet nytta MAE og RMSE.

MAE blir her snittfeilen i turar per time. Det er ein feil som er lett å tolke: kor mange turar i timen bommar modellen med i snitt. Det er ikkje nødvendigvis symmetrisk kor viktig feilen her er i eit businessperspektiv. For operatøren vil det kosta meir å bomma for lågt (ikkje nok syklar) med for høgt (ledige syklar). I tillegg kan det vera nyttig å samanlikna med RMSE, der feila er kvadrert. Der blir store avvik straffa hardare, som tel mykje for ein som skal planlegga her. Viss RMSE er mykje større enn MAE kan ein gå ut frå at det er nokre store bom i prediksjonane. Asymmetrien kan eg prøva å adressera med å sjekka snittet av feilen *med* forteikn (`np.mean(y_pred - y_sann)`).

1.3 Ressursar

Prosjektet krev lite ressursar:

- **Personell:** éin student, og ei lita arbeidsveke
- **Maskinvare:** vanleg laptop
- **Programvare:** Python med pandas, scikit-learn og Streamlit
- **Data:** opne data frå Bergen Bysykkel og MET (seklima)
- **Drift:** Streamlit Community Cloud (gratis)

1.4 Avgrensingar

Viktig avgrensing for prosjektet (hadde det vore ekte) er at bysykkelordninga i dagens form blir avslutta etter 2026-sesongen, og at det kjem ei ny ordning frå 2027 (*Bysykkelordninga i Bergen*, 2026)

For at ikkje omfanget skal bli for stort vil eg i dette prosjektet avgrensa meg til å sjå på det totale talet turar på ein dato med gitte vêr, vind og nedbørstilhøve. Framtidige utvidingar kan vera å inkludera meir informasjon om vêret og predikere per stasjon.

Avgrensingar i data og drift kjem eg attende til i del 2 om data og del 4 om drift.

2 Data

2.1 Kjelder og lisensar

Turane kjem frå Bergen Bysykkel sine opne data med ei CSV-fil per månad frå juni 2018 til september 2026 (*Åpne data - Bergen Bysykkel*, u.å.). Kvar rad er ein tur med informasjon om start- og slutttid, lengde og start- og sluttstasjon/plassering. Dataa er gjort tilgjengelege med Norsk lisesn for offentlege data (NLOD 2.0). Vêrdata kjem frå Norsk Klimaservicesenter (seklima) med CC BY 4.0 lisens (*Observasjoner og værstatistikk - Seklima*, u.å.). Dataa gjeld målestasjonen Bergen - Florida (SN50540). Eg nytta lufttemperatur, nedbør siste time og middelvind. Heilagdagar er henta frå Python-pakken `holidays`.

2.2 Label

Målvariabelen er talet på turar som startar i løpet av ein heil time i heile Bergen. Han blir rekna ut av å telje opp turar frå loggen (rådata) så me treng ikkje noko manuell merking utover tidspunkt. Labelen vil vera konsistent så lenge ein tur blir definert likt heile perioden, noko som blir sikra av å bruka same rydderegler på heile perioden.

Eit poeng her er at labelen er gjennomførte turar og ikkje etterspurnad. Behovet som føl med ein full eller tom stasjon vil med det ikkje bli fanga opp av datasettet. Det er med det sannsynleg at modellen underestimerer dei travlaste timane.

2.3 Rydding av turdata

Dei 100 månadsfilene inneheld til saman 4 664 902 turar. Medianturen varer om lag 8 minutt, men nokre turar varer frå 0 sekund til 15 dagar. Eg fjerna 436 turar under 60 sekund og 2 768 turar over tre timar, til saman 3 204 turar (0,07 %). Nokre av dei korte *kan* vera ekte turar mellom stasjonar som ligg tett, men det gjeld så få turar at det ikkje påverkar timetala.

Tidsstempla er i UTC. Eg kontrollerte dette ved å sjå at morgontoppen kjem kl. 08 norsk tid, og at tala føl opningstidene til operatøren. Turane vart talde per time i UTC, slik at overgangane til og frå sommartid ikkje gir doble eller manglande timar. Timar utan turar fekk verdien 0. 2 døgn utan turar vart fjerna, sidan tenesta då var stengd (mest truleg).

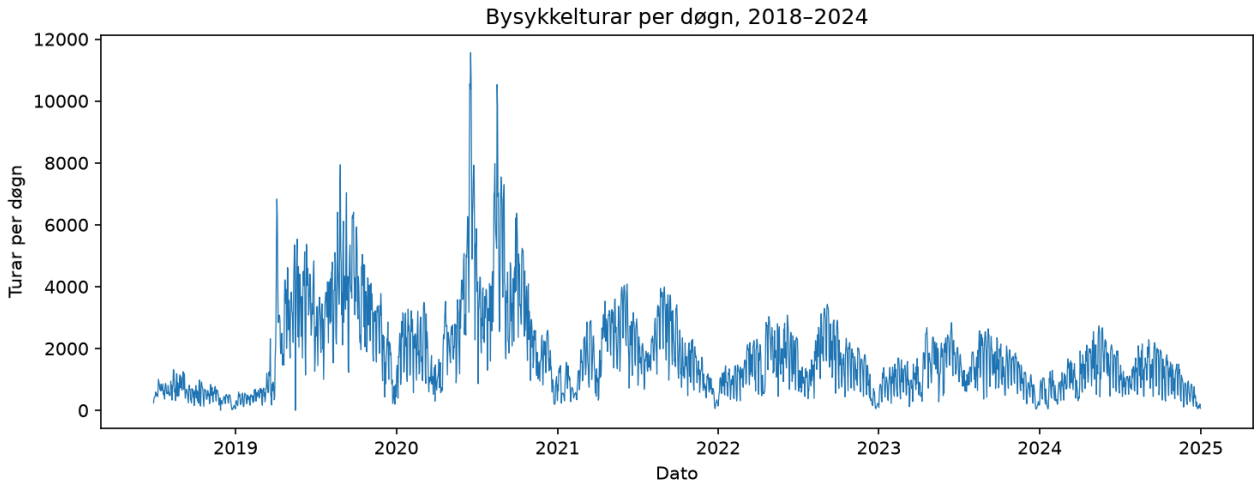
2.4 Rydding av vêrdata

Vêrdataene har 72 384 timar utan dublettar og utan manglande timar. Tidspunkta er oppgitte i norsk normaltid (UTC+1 heile året) og vart gjorde om til UTC. 17 timar hadde negativ nedbør, truleg målestøy, og vart sette til 0. Vinden mangla i 31 periodar. Dei 29 korte hola (1–3 timar) vart fylte ved lineær interpolasjon. To lengre hol, 43 timar i juni 2024 og 508 timar frå 21. februar til 14. mars 2025, vart fjerna saman med to timar utan nedbørsmåling.

Nedbør markert som kl. 09 gjeld timen 08–09, medan turtimen 08 dekkjer 08–09. Nedbøren vart difor flytta éin time tilbake før samanslåinga.

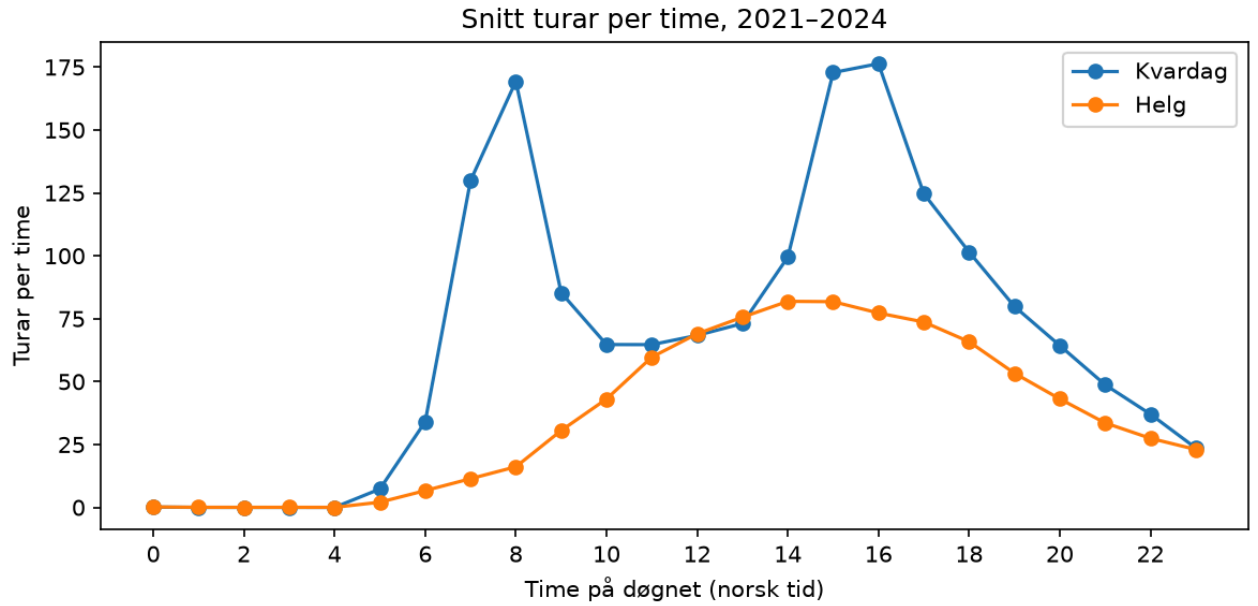
Bysykkeltenesta er open kl. 05–24 (*Bysykkelordninga i Bergen*, u.å.). Timane kl. 00–04 vart fjerna, sidan 0 turar då betyr stengt og ikkje låg etterspurnad. Ferdig tabell har 56 821 timar frå 29.06.2018 til 30.09.2026.

2.5 Utforsking



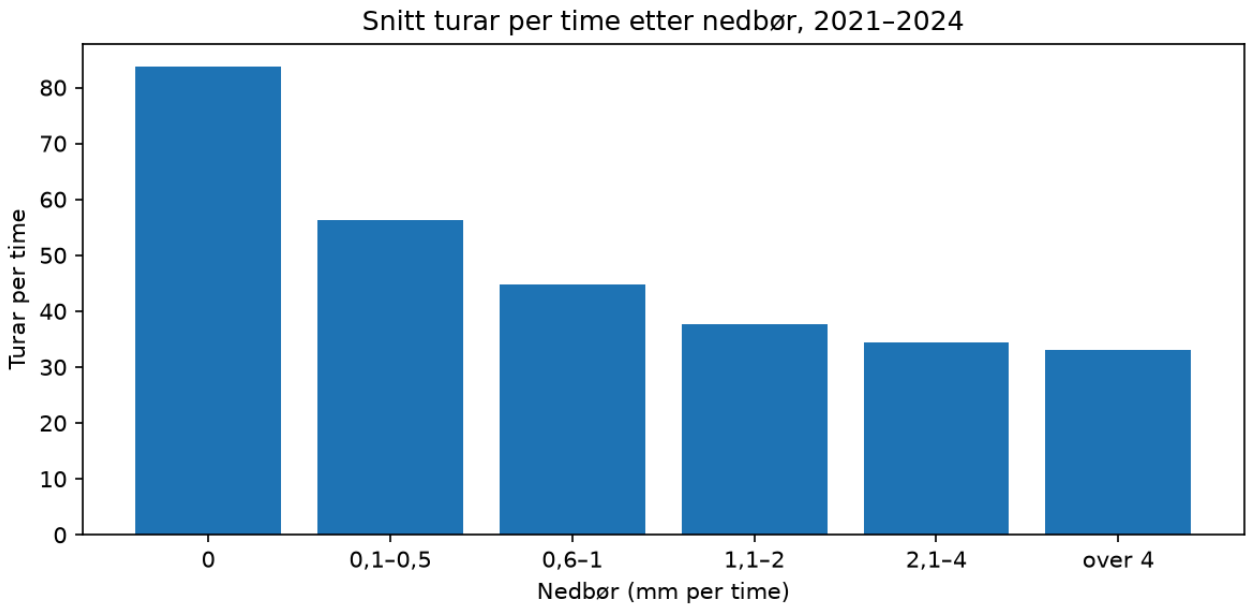
Figur 1: Turar per døgn

Figur 1 viser at i starten, rett etter opninga og eit stykke ut i 2019, er det låge tal som mest truleg skuldast at det var eit lågare tal syklar og stasjonar i starten. I tillegg ser me årstidvariasjon der bruken er lågare på vinterstid enn på sommaren. Det er og interessant å sjå kor høg bruken var i pandemien, mest truleg knytt til lite bruk av kollektivtilbod pga smitte.



Figur 2: Turar per time, kvardag og helg

Ser av Figur 2 at det her er to toppar på kvardagssnittet, før og etter jobb, og i helgene ein slakare topp midt på dagen til og frå aktivitetar.



Figur 3: Turar per time mot nedbør

Figur 3 viser turar per time etter mm nedbør per time. Ser at det første regnet kostar ganske mykje, før det kostar mindre og mindre.

Figur 1 dekkjer 2018–2024, Figur 2 og Figur 3 dekkjer 2021–2024. Teståret er ikkje med i nokon av dei..

2.6 Features

FEATURE	TYPE	KJELDE
time (5–23)	kategorisk	starttid, norsk tid
vekedag (0–6)	kategorisk	starttid, norsk tid
månad (1–12)	kategorisk	starttid, norsk tid
heilagdag (0/1)	kategorisk	`holidays`
temperatur	numerisk	seklima
nedbør	numerisk	seklima
vind	numerisk	seklima

2.7 Tidsdeling

Dataa er delte på tid: trening 2021–2023, validering 2024 og test 2025. Ei tilfeldig deling ville gitt for optimistiske tal, fordi timar som ligg ved sidan av kvarandre er nesten like (Géron, 2023). 2018–2020 er ikkje med i treninga, fordi bruksnivået då var svært ulikt seinare år: lågt i oppstarten og uvanleg høgt under pandemien (Figur 1). Treningsdata bør likna dataa modellen skal brukast på. 2026 er ikkje med, fordi dataa berre går til 30. september. Eit ufullstendig år ville gitt eit skeivt bilete av årstidene/sesongane i testen.

Etter litt utforsking såg eg at bruken gjekk ned med om lag 15 % i året frå 2021 til 2025. Ein baseline trena på 2021–2023 bomma i snitt 21,6 turar for høgt per time på valideringsåret (MAE 25,4). Trena berre på 2023 fall skeivheita til 9,5 og MAE til 20,6. Eg trenar difor på det siste heile året. I drift svarar det til at modellen blir trena på nytt kvart år.

2.8 Personvern

Turdataa er anonymiserte, men tidspunkt og stasjon kan i prinsippet avsløra rutinane til personar som syklar same tur kvar dag. Modellen og appen brukar berre talet på turar per time for heile byen, så enkeltpersonar kan ikkje identifiserast. Repoet inneheld heller ingen enkeltturar, berre den samla timetabellen.

3 Modellering

3.1 Baseline og treningsperiode

Baselinen er den manuelle løysinga frå del 1: snittet av turar for same time, vekedag og månad i treningsdata. Han har eit eige snitt for kvar kombinasjon og fangar dermed døgnrytmen, men ser ikkje vêret.

Bruken fall med om lag 15 % i året frå 2021 (Figur 1). Ein baseline trena på 2021–2023 bomma i snitt 21,6 turar for høgt per time i valideringsåret (MAE 25,4). Trena berre på 2023 fall skeivheita til 9,5 og MAE til 20,6. Alle modellane er difor trena på det siste heile året før året dei blir evaluerte på: 2023 for validering og 2024 for testen.

3.2 Modellar

Eg prøvde fire modellar i tillegg til baselinen:

- **Ridge** er lineær regresjon med straff for store vekter. Han er enkel og lett å tolka, men kan berre leggja saman effektar.
- **Ridge med samspel** har ein ekstra kategori som kombinerer time og dagtype (kvardag eller helg).
- **Random forest** er mange beslutningstre trena på tilfeldige utval, der svaret er snittet av trea.
- **Gradient boosting** byggjer tre etter tre, der kvart nytt tre rettar feila til dei førre. Eg brukte Poisson-tap, som passar til teljedata.

For Ridge vart kategoriane one-hot-koda og tala standardiserte, tilpassa berre på treningsdata. Trebaserte modellar treng ingen av delene.

Tabell 1: Resultat på trening (2023) og validering (2024). MAE og RMSE er i turar per time.

MODELL	MAE TRENING	MAE VALIDERING	RMSE VALIDERING	SKEIVHEIT VALIDERING
Baseline	16,1	20,6	30,1	9,5
Ridge	23,9	25,3	32,9	11,5
Ridge med samspel	19,0	21,1	27,8	11,4
Random forest	10,1	16,7	24,1	10,7
Gradient boosting	10,0	15,2	21,5	9,4

Ridge var dårlegare enn baselinen. Han legg saman effektane kvar for seg og kan ikkje læra at rushtoppane berre finst på kvardagar (Figur 2). Med samspelskategorien fall MAE frå 25,3 til 21,1, og RMSE vart lågare enn for baselinen. Vala for alpha (0,1–100) endra lite, truleg fordi modellen har mange rader og relativt få kolonnar.

Dei trebaserte modellane lærer slike samspel av seg sjølve og var klart best. Gradient boosting hadde lågast feil på valideringa. Gapet mellom trening (MAE 10,0) og validering (15,2) har to årsaker: noko overtilpassing, og at bruken i 2024 låg lågare enn i 2023. Skeivheita på 9,4 viser at nivåskiftet står for ein stor del.

3.3 Test

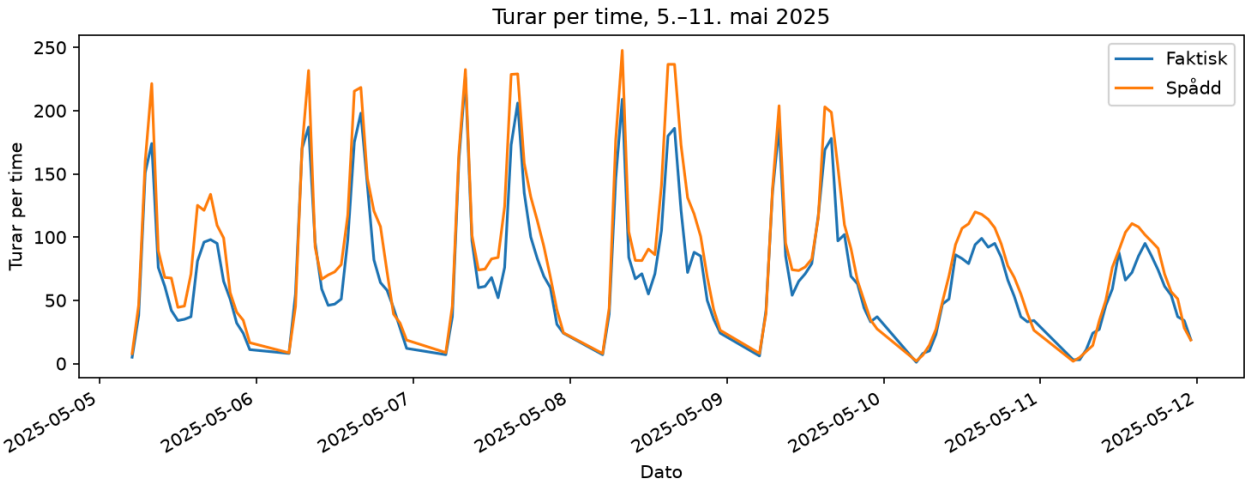
Gradient boosting vart trena på nytt på 2024 og testa éin gong på 2025.

Tabell 2: Resultat på testsettet (2025).

MODELL	MAE	RMSE	SKEIVHEIT
Baseline	19,1	29,4	14,5
Gradient boosting	16,1	23,6	14,1

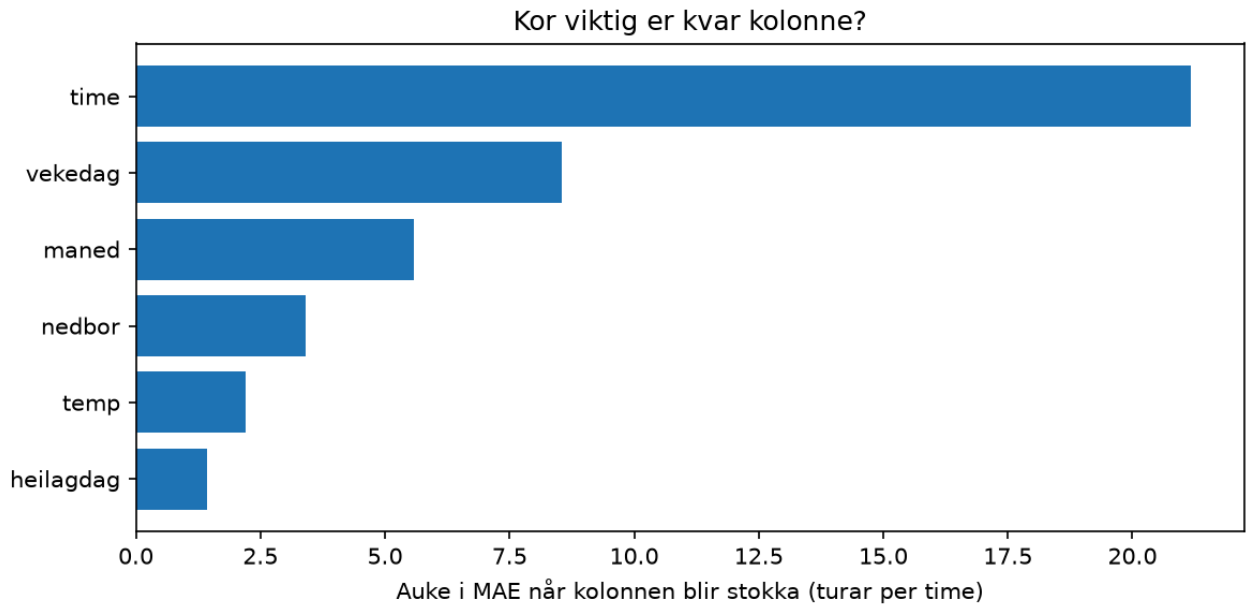
Modellen har 16 % lågare MAE og 20 % lågare RMSE enn baselinen og oppfyller dermed minimumskravet. Snittet i 2025 var likevel berre 44 turar per time, så feilen er stor. Mesteparten kjem av at bruken fall 23 % frå 2024 til 2025, ein trend modellen ikkje kjenner til.

3.4 Feilanalyse og viktigheit



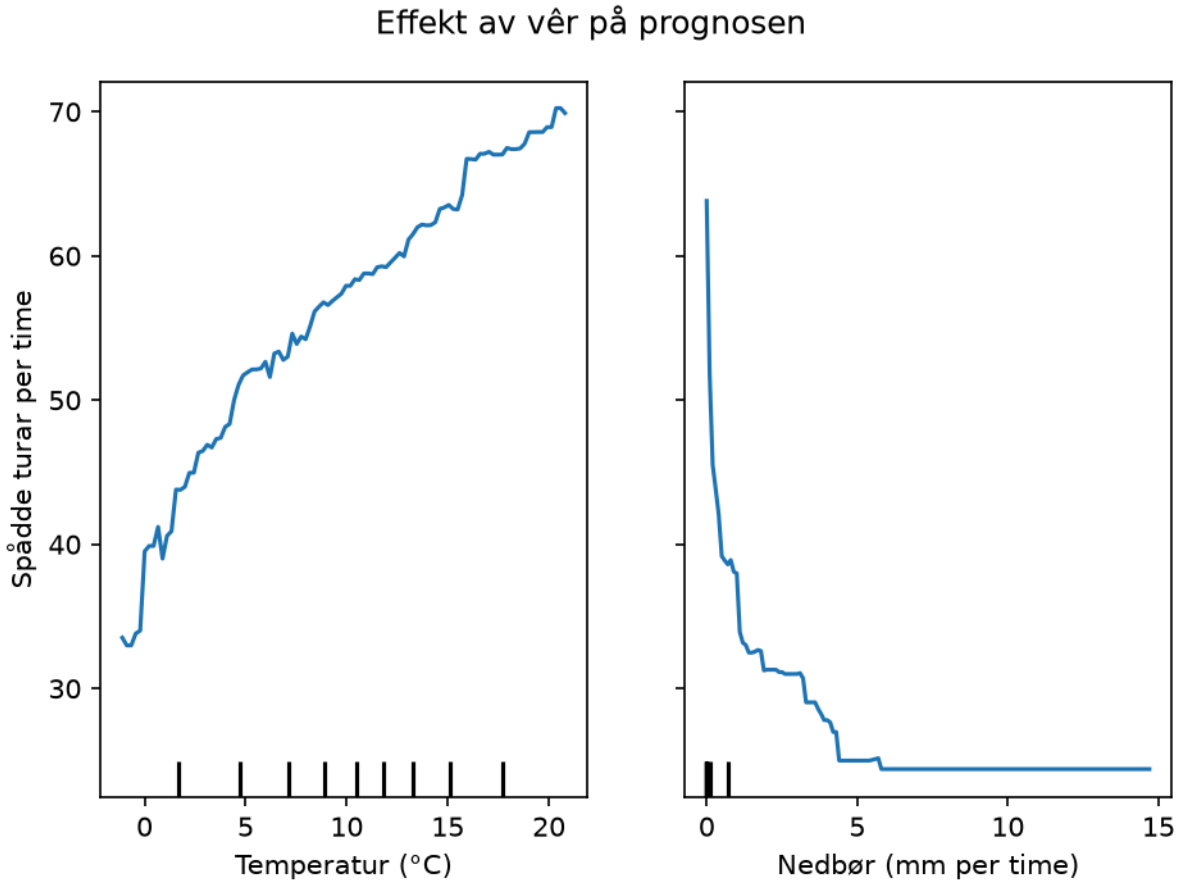
Figur 4: Spådde og faktiske turar per time, 5.–11. mai 2025. Nattetimane (kl. 00–04) er ikkje med.

Modellen treff døgnmønsteret godt, med rushtoppar på rett tid og breie kurver i helga (Figur 4). Han ligg likevel systematisk for høgt, mest i rushet på kvardagar.



Figur 5: Auke i MAE når kvar kolonne blir stokka tilfeldig (testsettet).

Klokkeslett og vekedag er dei viktigaste kolonnane, deretter månad og vêr (Figur 5). Vind hadde ingen effekt, verken på validerings- eller testsettet, og vart fjerna for å forenkla modellen og appen. Valet bygde på valideringsdata, og testen vart køyrd på nytt etterpå med nesten same resultat.



Figur 6: Spådde turar etter temperatur og nedbør når alt anna står fast.

Spådde turar aukar jamt med temperaturen og fell brått ved lett regn, før kurva flatar ut (Figur 6). Over om lag 6 mm har modellen nesten ingen data og spår det same uansett nedbørsmengd.

KLAD KLADD KLADD KLADD

«Ridge legg saman effektane kvar for seg og kan ikkje læra at rushtoppane berre finst på kvardagar. Med ein kombinert kategori for time og dagtype fall MAE frå 25,3 til 21,0.

På teståret 2025 fekk gradient boosting MAE 16,0 og RMSE 23,4, mot 19,1 og 29,4 for baselinen. Modellen oppfyller dermed minimumskravet. Skeivheita på 14 turar per time viser at mesteparten av feilen kjem av at bruken fall med 23 % frå 2024 til 2025. Modellen kjenner ikkje til denne trenden.

Modellen treff døgnmønsteret godt, med rushtoppar på rett tid og breie kurver i helga (Figur 4). Han ligg likevel systematisk for høgt, mest i rushet på kvardagar.»

«Klokkeslett og vekedag er dei viktigaste kolonnane (Figur 5), og vind betyr ingenting for modellen. Spådde turar aukar jamt med temperaturen og fell brått ved lett regn, før kurva flatar ut (Figur 6). Over om lag 6 mm har modellen nesten ingen data og spår det same uansett nedbørsmengd.»

Vind hadde ingen påverknad på modellen, verken på validerings- eller testsettet, og vart fjerna for å forenkla modellen og appen. Valet byggjer på valideringsdata, og testen vart køyrd på nytt med den forenkla modellen.

- Beskriv hvilken eller hvilke maskinlæringsmodeller dere har utforsket. Beskriv hvordan dere har estimert baseline-ytelse og baseline-oppførsel. Baseline-ytelse kan avdekkes via modeller eller enkle ikke-maskinlæringsbaserte løsninger, ved å lete etter resultater oppnådd av andre på samme oppgave, eller ved å estimere «human level performance» der det er relevant.
- Gi verdiene dere målte for alle metrikkene, og bruk gjerne grafer og tabeller for å visualisere resultatene.
- Beskriv hvordan dere eventuelt har undersøkt feil-prediksjoner og «feature importance», og hvordan dette kan brukes til å forbedre modellene.

4 Deployment

2. Målt vêr er ikkje vêrmelding

Under trening får modellen vêret slik det faktisk vart, målt på Florida. Når driftsleiaren brukar appen om kvelden for å planleggje morgondagen, finst ikkje målingane enno, så ho må bruke vêrmeldinga. Vêrmeldinga bommar av og til, til dømes med regn som kjem seinare eller ikkje i det heile. Då får modellen feil input, og prognosen blir dårlegare enn testfeilen din viser.

Døme på setning:

Modellen er trena og testa med målt vêr, men i bruk får han vêrmelding. Feil i vêrmeldinga kjem i tillegg til feilen i modellen, så den reelle feilen blir større enn MAE på testsettet.

Hvordan er modellen(e) blitt satt i drift? Hvordan skal prediksjonene brukes? Hva vil være nødvendig for monitorering og vedlikehold av maskinlæringssystemet? Hvis relevant, hvilke planer har du for å forbedre systemet etter at det er satt i drift? Gi eventuelt lenke til nettside, screenshots av applikasjonen, eller liknende.

5 Refleksjonar

6 Referansar

Bysykkelordninga i Bergen. (u.å.). https://miljoloftet.no/prosjektliste/ikkje-strekningsvise-prosjekt/bysykkelordninga-i-bergen/

Bysykkelordninga i Bergen. (2026). https://miljoloftet.no/prosjektliste/ikkje-strekningsvise-prosjekt/bysykkelordninga-i-bergen/

Géron, A. (2023). *Hands-on machine learning with Scikit-Learn, Keras and TensorFlow: concepts, tools, and techniques to build intelligent systems* (Third edition). O'Reilly Media, Inc.

Observasjoner og værstatistikk - Seklima. (u.å.). https://seklima.met.no/

Om Bergen Bysykkel - Bergen Bysykkel. (2026). https://bergenbysykkel.no/om

Åpne data - Bergen Bysykkel. (u.å.). https://bergenbysykkel.no/apne-data

List opp kilder du har brukt til å utarbeide prosjektbeskrivelsen.